MILESTONE 3

SMART WAREHOUSE MANAGEMENT AGENT
Basis Pengetahuan Korpus dan Vector Semantic Search

Mata Kuliah	10S3001 – Kecerdasan Buatan (Artificial Intelligence) (+P)
Kode Tugas	Tugas 3 (Milestone 3 – W07) (Milestone Proyek Terpadu)
Judul Milestone 3	Pembangunan Basis Pengetahuan Korpus & Vector Semantic Search
Kelompok	19
Dosen Pengampu	Samuel Indra Gunawan Situmeang
Semester / T.A.	Gasal 2026/2027
Repositori GitHub	https://github.com/NicolasButarbutar/Smart-Warehouse-Agent

Disusun oleh:

Nama	NIM
Nicolas J Grace Butarbutar	12S24038
Indah Triyuni Siahaan	12S24052
Swasti Maristella Sihombing	12S24030

PROGRAM STUDI SARJANA SISTEM INFORMASI
FAKULTAS INFORMATIKA DAN TEKNIK
ELEKTRO INSTITUT TEKNOLOGI DEL

2026/2027

1. Pendahuluan

1.1 Posisi Milestone 3 dalam Proyek

Pada Milestone 1, Smart Warehouse Agent untuk studi kasus Gudang Nusantara Logistik memutuskan lokasi dan rute barang dengan UCS dan A*. Milestone 2 menambahkan penjadwalan shift staf dengan CSP (AC-3 dan Backtracking). Kedua modul itu menjawab pertanyaan keputusan, tetapi belum dapat menjawab pertanyaan pengetahuan seperti “berapa suhu ruang beku?” atau “bolehkah operator tanpa lisensi mengemudikan forklift?”.

Jawaban pertanyaan tersebut tersimpan pada SOP, kebijakan, manual, dan ringkasan regulasi. Pencarian kata kunci sering gagal karena karyawan memakai kata yang berbeda dari kata pada dokumen. Milestone 3 membangun memori semantik yang menemukan potongan dokumen berdasarkan makna, dan yang berani menolak bila pertanyaan berada di luar cakupan korpus. Fondasi ini akan dihubungkan ke model bahasa besar pada tahap Retrieval-Augmented Generation (RAG)

1.2 Pemetaan terhadap Rubrik

Komponen Rubrik	Bobot	Bagian Laporan	Artefak di Repositori
Kualitas Data Korpus & Prapemrosesan	25%	Bab 2 dan Bab 3	data/raw/corpus/, src/kb/preprocess.py, src/kb/chunking.py
Pipeline Embedding & Vector Store ChromaDB	45%	Bab 4 dan Bab 7	src/kb/embeddings.py, vector_store.py, retriever.py, data/vectorstore/
Akurasi & Analisis Temu Balik Semantik	30%	Bab 5 dan Bab 6	data/benchmark/queries.json, src/kb/benchmark.py, results/benchmark_results.json

Tabel 1.1 Pemetaan rubrik Milestone 3 ke bagian laporan dan artefak

2. Korpus Dokumen Enterprise

2.1 Sumber dan Sifat Korpus

Korpus terdiri atas 18 dokumen (10 MD. 4 PDF. 4 TXT) dengan total 7.722 kata bersih. Jumlah ini melampaui syarat minimal 10–15 dokumen. Seluruhnya merupakan dokumen **sintetis** untuk perusahaan fiktif Gudang Nusantara Logistik, sehingga prosedur dan angka internalnya tidak berasal dari perusahaan nyata. REG-01 merangkum peraturan yang berlaku umum, yaitu UU 13/2003 sebagaimana diubah UU 6/2023, PP 35/2021, dan Permenaker 8/2020, dan dokumennya sendiri menyatakan bahwa ringkasan itu bukan pengganti teks resmi.

ID	Judul Dokumen	Jenis	Format	Kata
SOP-01	SOP Penerimaan Barang Masuk (Inbound)	SOP	MD	444
SOP-02	SOP Put-Away dan Slotting Barang	SOP	MD	431
SOP-03	SOP Picking dan Packing Pesanan	SOP	TXT	416
SOP-04	SOP Pengiriman Keluar dan Serah Terima Kurir	SOP	MD	401
SOP-05	SOP Penyimpanan Rantai Dingin (Cold Storage)	SOP	PDF	455
SOP-06	SOP FEFO dan Pengendalian Barang Kedaluwarsa	SOP	MD	404
SOP-07	SOP Penanganan Barang Fragile dan Oversize	SOP	MD	418
SOP-08	SOP Stock Opname dan Penyelesaian Selisih Stok	SOP	TXT	403
SOP-09	SOP Retur Barang dan Zona Karantina	SOP	MD	425
SOP-10	SOP Pengoperasian Forklift dan AGV	SOP	PDF	439
SOP-11	SOP Tanggap Darurat Kebakaran dan Evakuasi	SOP	MD	442
KEB-01	Kebijakan Penjadwalan Shift dan Waktu Kerja	Kebijakan	PDF	437
KEB-02	Kebijakan Lembur, Cuti, dan Tukar Shift	Kebijakan	MD	411
KEB-03	Kebijakan Keselamatan, Kesehatan Kerja, dan APD	Kebijakan	MD	448
KEB-04	Kebijakan Keamanan Akses Gudang dan Data WMS	Kebijakan	TXT	433
KEB-05	Kebijakan Mutu Layanan dan Indikator Kinerja Gudang	Kebijakan	MD	410
MAN-01	Manual Penggunaan WMS dan Perangkat Genggam	Manual	TXT	460
REG-01	Ringkasan Regulasi Ketenagakerjaan dan K3 untuk Operasi Gudang	Regulasi	PDF	445

Tabel 2.1 Daftar dokumen korpus

2.2 Representativitas terhadap Domain

Dokumen dipilih agar mencakup seluruh rantai proses gudang serta kebutuhan modul sebelumnya, bukan sekadar memenuhi jumlah. Isi korpus konsisten dengan data proyek: identitas rak R01–R16, DOCK_IN, DOCK_OUT, STAGING, tiga shift, dan batas 40 jam per minggu pada solver M2.

Kebutuhan	Dokumen	Keterkaitan
Salah taruh dan selisih stok (M1)	SOP-01, SOP-02, SOP-08	Aturan pemindaian, slotting, dan penyelesaian selisih.
Waktu picking tinggi (M1)	SOP-02, SOP-03, KEB-05	Zona fast-moving, rute terpendek, dan target kinerja.
Keputusan rute agen (M1)	SOP-02, SOP-10	Rute A*, lorong terhalang, jalur bersama AGV dan forklift.
Batasan penjadwalan (M2)	KEB-01, KEB-02, REG-01	Aturan C0–C4 dan dasar regulasinya, dalam bentuk bahasa alami.
Mutu dan keamanan barang	SOP-05, SOP-06, SOP-07, SOP-09	Rantai dingin, FEFO, barang rapuh, dan retur.
Risiko operasional	SOP-04, SOP-11, KEB-03, KEB-04, MAN-01	Serah terima, darurat, K3, keamanan, dan gangguan sistem.

Tabel 2.2 Keterkaitan korpus dengan pain points dan modul proyek

2.3 Pembersihan Teks

Berkas PDF dan TXT sengaja dibiarkan membawa gangguan yang lazim pada dokumen perusahaan: header dan footer berulang, nomor halaman, kutip melengkung, spasi ganda, akhir baris Windows, dan baris yang terbungkus. Modul preprocess.py membersihkannya secara otomatis dengan urutan berikut.

- **Normalisasi karakter:** Unicode NFKC, penyeragaman kutip dan tanda hubung, serta penghapusan karakter kontrol dan karakter tak terlihat.
- **Header dan footer:** baris yang muncul pada minimal 60% halaman dibuang, ditambah pola nomor halaman dan label dokumen terkendali.
- **Rekonstruksi struktur:** pemenggalan akhir baris disambung, baris dalam satu bab digabung, dan judul bab bernomor dikenali tanpa keliru mengenali langkah prosedur sebagai judul.
- **Validasi:** dokumen yang kosong setelah dibersihkan menghentikan proses, dan pengujian otomatis memastikan tidak ada sisa header pada korpus.

Format	Dokumen	Halaman	Kata mentah	Kata bersih	Baris gangguan dibuang
PDF	4	8	1888	1776	24
TXT	4	4	1760	1712	8
MD	10	10	4234	4234	0
Total	18	22	7882	7722	32

Tabel 2.3 Dampak pembersihan pada korpus

Pembersihan membuang 32 baris gangguan atau 160 kata (2.0% kata mentah) tanpa mengurangi isi bab. Hasilnya disimpan pada data/processed/corpus_clean/ agar dapat diperiksa.

3. Strategi Chunking

3.1 Algoritma Word-Aware Recursive Chunking

Pemotongan dilakukan bertingkat: bab, paragraf, kalimat, klausa, lalu kata. Tingkat yang lebih halus hanya dipakai bila satu unit melebihi batas, sehingga kalimat tetap utuh selama muat. Batas diukur dalam jumlah kata. Overlap tidak mengambil N kata secara mekanis, melainkan mengulang kalimat utuh terakhir dari potongan sebelumnya sampai batas overlap, dan tidak melintasi batas bab agar konteks dua topik tidak bercampur.

```
function CHUNK(bab, ukuran, overlap):
    unit <- pecah bab menjadi kalimat (dipecah lagi
hanya bila > ukuran)     for u in unit:          if
kata(potongan) + kata(u) > ukuran:
            simpan potongan              potongan <-
kalimat utuh terakhir dengan total kata <= overlap
tambahkan u ke potongan
    simpan potongan terakhir bila memuat kalimat baru
```

Teks yang di-encode diberi awalan judul dokumen dan nama bab (“judul - bab: isi”). Dengan demikian, potongan seperti “Alarm merah berbunyi…” tetap membawa konteks bahwa ia berasal dari SOP rantai dingin. Isi potongan disimpan terpisah dari awalan ini.

3.2 Justifikasi Parameter Size dan Overlap

Parameter tidak ditetapkan secara intuitif, melainkan melalui tiga dasar berikut.

- **Batas model.** Model keluarga paraphrase-multilingual memiliki max_seq_length 128 token. Token di luar batas diabaikan tanpa peringatan, sehingga potongan yang terlalu panjang kehilangan bagian akhirnya saat di-encode. Sistem karena itu menghitung token setiap potongan dengan tokenizer model yang dipakai, termasuk awalan judul, dan konfigurasi dengan lebih dari 5% potongan terpotong tidak dapat dipilih.

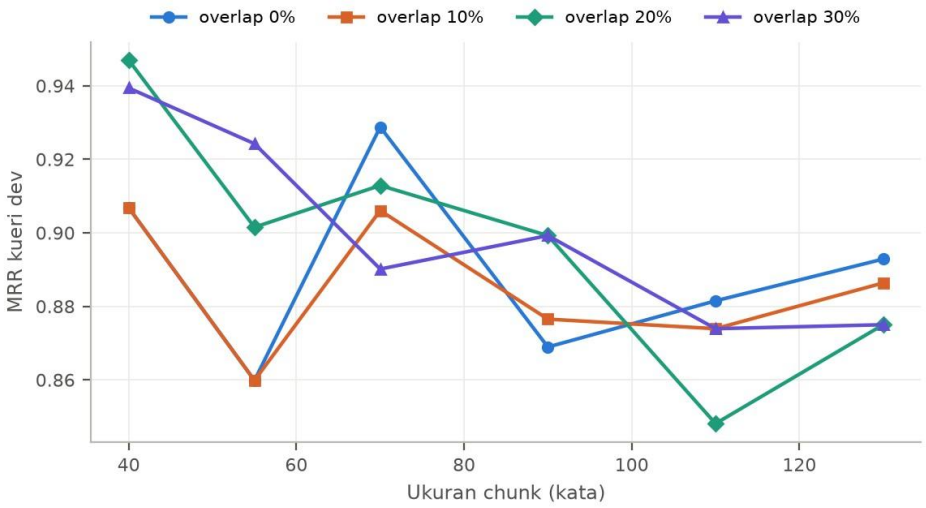
- **Eksperimen terkendali.** Enam ukuran (40, 55, 70, 90, 110, 130 kata) dan empat rasio overlap (0%, 10%, 20%, 30%) dievaluasi pada kueri dev, sehingga ada 24 konfigurasi.
- **Aturan pilih yang ditetapkan lebih dulu.** Di antara konfigurasi yang lolos batas token, dipilih MRR tertinggi, lalu Answer@3, lalu AUC out-of-domain, lalu jumlah chunk tersedikit. Kueri test tidak dipakai pada tahap ini.

Ukuran	Overlap	Jumlah chunk	Rata-rata kata	Maks. kata	Berakhir di akhir kalimat	Chunk ber-overlap
40	0	234	30.7	40	100.0%	0
40	8	245	30.5	40	100.0%	61
55	0	178	40.4	55	100.0%	0
55	11	181	42.3	55	100.0%	62
70	0	144	49.9	70	100.0%	0
70	14	149	51.6	70	100.0%	53
90	0	114	63.0	90	100.0%	0
90	18	114	66.7	90	100.0%	34
110	0	99	72.6	109	100.0%	0
110	22	99	76.2	109	100.0%	22
130	0	88	81.7	129	100.0%	0
130	26	88	84.6	129	100.0%	14

Tabel 3.1 Struktur potongan pada sebagian grid (terukur dari korpus, tanpa model)

Pada seluruh 24 konfigurasi, semua potongan berakhir di akhir kalimat, sehingga pemotongan tidak memutus makna kalimat. Jumlah chunk ber-overlap menurun pada ukuran besar karena lebih banyak bab yang sudah muat dalam satu potongan.

Ukuran	Overlap	Chunk	Token rata-rata	% terpotong	Hit@1	MRR	Answer@3	AUCOOD
40	0	234	70	0.0	0.864	0.907	0.818	0.962
40	4	239	70	0.0	0.864	0.907	0.818	0.958
40	**8**	**245**	**70**	**0.0**	**0.909**	**0.947**	**0.864**	**0.966**
40	12	254	71	0.0	0.909	0.939	0.864	0.973
55	0	178	84	0.0	0.773	0.860	0.773	0.985
55	6	179	85	0.0	0.773	0.860	0.773	0.985
55	11	181	88	0.0	0.818	0.902	0.864	0.989
55	16	193	89	0.0	0.864	0.924	0.864	0.970
70	0	144	99	12.5	0.909	0.929	0.818	0.970
70	7	147	98	10.9	0.864	0.906	0.864	0.973
70	14	149	102	12.1	0.864	0.913	0.818	0.973
70	21	157	105	13.4	0.818	0.890	0.864	0.981
90	0	114	118	49.1	0.818	0.869	0.818	0.966
90	9	114	120	50.0	0.818	0.877	0.818	0.966
90	18	114	124	52.6	0.864	0.899	0.864	0.970
90	27	114	129	57.9	0.864	0.899	0.864	0.970
110	0	99	133	62.6	0.818	0.881	0.864	0.977
110	11	99	134	62.6	0.818	0.874	0.864	0.977
110	22	99	138	62.6	0.773	0.848	0.864	0.970
110	33	99	142	63.6	0.818	0.874	0.864	0.966
130	0	88	146	70.5	0.818	0.893	0.864	0.977
130	13	88	148	70.5	0.818	0.886	0.864	0.973
130	26	88	151	70.5	0.818	0.875	0.864	0.966
130	39	88	154	70.5	0.818	0.875	0.864	0.970



Gambar 3.1 MRR kueri dev terhadap ukuran chunk dan overlap

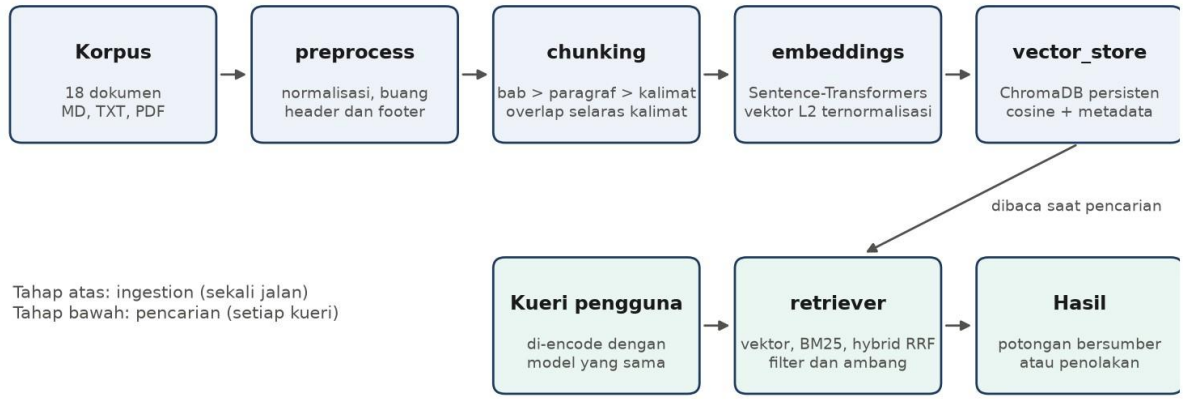
Hasil eksplorasi grid pada Tabel 3.2 dan Gambar 3.1 memperlihatkan trade-off yang nyata antara ukuran potongan, kapasitas panjang konteks model, dan keutuhan semantik. Model terpilih (paraphrase-multilingual-mpnet-base-v2) memiliki batas keras panjang sekuens sebesar 128 token.

Konfigurasi dengan ukuran potongan 70 kata ke atas mulai mengalami pemotongan token (truncation) sebesar 10.9% hingga 70.5% pada ukuran 130 kata. Pemotongan token berisiko fatal karena menghilangkan kalimat atau kata kunci penting yang berada di bagian ekor potongan saat proses pembuatan embedding.

Pada rentang ukuran potongan yang aman dari pemotongan token (40 dan 55 kata, dengan persentase terpotong 0.0%), konfigurasi ukuran 40 kata dengan overlap 8 kata (rasio overlap 20%) mencatatkan kinerja temu balik tertinggi pada himpunan kueri dev: Hit@1 mencapai 0.909, MRR mencapai 0.947, Answer@3 mencapai 0.864, dan AUC penolakan out-of-domain sebesar 0.966. Keberhasilan konfigurasi ini didorong oleh granularitas potongan yang terfokus pada satu gagasan atau prosedur spesifik, didukung awalan judul dokumen dan bab, serta overlap selaras kalimat utuh yang menjembatani kesinambungan konteks antar-potongan tanpa melintasi batas bab.

4. Pipeline Embedding dan Vector Store

4.1 Arsitektur Modular



Gambar 4.1 Arsitektur pipeline basis pengetahuan

Modul	Tanggung Jawab
preprocess.py	Memuat MD, TXT, PDF; membersihkan teks; mengenali struktur bab.
chunking.py	Word-aware recursive chunking dengan overlap selaras kalimat.
embeddings.py	Pembungkus Sentence-Transformers, vektor L2, dan penghitung token.
ingest.py	Menyusun ID, teks encode, metadata, dan statistik potongan.
vector_store.py	Akses ChromaDB persisten dan indeks numpy eksak sebagai pembanding.
lexical.py / retriever.py	BM25, fusi hybrid RRF, filter metadata, dan penolakan out-of-domain.
evaluate.py / benchmark.py	Metrik, kalibrasi ambang, seleksi model dan chunking, evaluasi test.
kb_pipeline.py	Antarmuka baris perintah: all, ingest, search.

Tabel 4.1 Modul pada src/kb/

4.2 Pemilihan Model Embedding

Korpus berbahasa Indonesia dengan istilah gudang berbahasa Inggris (put-away, picking, cold storage), sehingga model multibahasa diduga lebih tepat. Dugaan ini diuji, bukan diasumsikan: model khusus bahasa Inggris dipakai sebagai pembanding, dan arsitektur Sentence-Transformers dipakai pada ketiganya. Pemenang ditentukan dari rata-rata MRR, Answer@3, dan AUC pada kueri dev.

Model	Dimensi	Maks. token	Hit@1	MRR	Answer@3	AUC OOD	Skor
all-MiniLM-L6-v2	384	256	0.318	0.460	0.409	0.735	0.535
paraphrase-multilingual-MiniLM-L12-v2	384	128	0.773	0.833	0.727	0.992	0.851
paraphrase-multilingual-mpnet-base-v2	**768**	**128**	**0.864**	**0.913**	**0.818**	**0.973**	**0.902**

Tabel 4.2 Perbandingan model pada kueri dev (baris tebal = terpilih)

Evaluasi empiris terhadap tiga arsitektur Sentence-Transformers pada Tabel 4.2 membuktikan pentingnya pemilihan model yang selaras dengan karakteristik linguistik korpus. Model monolingual bahasa Inggris all-MiniLM-L6-v2 mencatat skor seleksi terendah (0.535) dengan Hit@1 hanya 0.318 dan MRR 0.460. Hal ini disebabkan oleh ketidakmampuannya memetakan kosakata dan struktur kalimat bahasa Indonesia formal ke dalam ruang representasi semantik yang akurat, meskipun model tersebut memiliki kapasitas sekuens token yang lebih panjang (256 token).

Sebaliknya, model multilingual mampu menjembatani istilah teknis pergudangan bahasa Inggris
(seperti inbound, put-away, cross-docking, FEFO) dengan teks regulasi dan kebijakan berbahasa
Indonesia. Model paraphrase-multilingual-mpnet-base-v2 (dimensi 768) mengungguli varian MiniLM-L12 (dimensi 384) pada seluruh metrik utama, menghasilkan Hit@1 sebesar 0.864, MRR sebesar 0.913, Answer@3 sebesar 0.818, dan skor seleksi tertinggi 0.902. Vektor embedding 768 dimensi menyediakan kapasitas representasi yang lebih padat dan diskriminatif, sehingga terpilih sebagai representasi vektor utama untuk indeks persisten.

4.3 Penyimpanan ChromaDB Persisten

Indeks disimpan melalui chromadb.PersistentClient pada data/vectorstore/, dengan koleksi enterprise_kb berjarak cosine. Vektor dihitung sendiri lalu dinormalisasi L2, sehingga skor kemiripan adalah 1 − jarak cosine. Setiap kali koleksi dibangun, sistem membandingkan skor ChromaDB dengan perkalian titik vektor dan berhenti bila berbeda, sehingga skor pada laporan pasti cosine. Koleksi dibangun ulang secara idempoten dan menyimpan nama model serta parameter chunking.

Pemeriksaan	Hasil
Jumlah vektor tersimpan	245
Dimensi vektor	768
Model, ukuran chunk, overlap	sentence-transformers/paraphrase-multilingual-mpnet-base-v2, 40 kata, 8 kata
Potongan terpotong oleh model	0.0%
Dibuka ulang dari proses Python terpisah: jumlah vektor	245
Kueri dengan hasil identik setelah dibuka ulang	33 dari 33
Recall@5 HNSW terhadap pencarian eksak	1.000
Metadata terisi lengkap	100.0%

Tabel 4.3 Bukti pengindeksan dan persistensi

4.4 Metadata untuk Hybrid Search

Setiap vektor menyimpan 21 kolom metadata. Kolom ini memungkinkan penyaringan terstruktur, audit asal jawaban, dan sitasi sumber pada tahap RAG.

Kelompok	Kolom	Kegunaan
Identitas	doc_id, judul, file_sumber, format_sumber	Sitasi sumber dan pelacakan ke berkas asli.
Klasifikasi	jenis, kategori, departemen, level_akses, kata_kunci	Filter topik dan kontrol akses.
Tata kelola	pemilik, versi, tanggal_berlaku, tahun_berlaku	Memilih dokumen yang masih berlaku.
Struktur	bab, bab_index, chunk_index, total_chunk_dokumen	Mengambil potongan tetangga dan menampilkan bab.
Teknis	n_kata, n_kata_overlap, n_token	Audit kualitas chunking.
Domain	rak_terkait	Menghubungkan pengetahuan dengan rak pada modul M1.

Tabel 4.4 Skema metadata per potongan

Mode hybrid menggabungkan peringkat vektor dengan BM25 melalui Reciprocal Rank Fusion dengan k = 60, sehingga kode persis seperti E-305 tetap mudah ditemukan tanpa kehilangan kemampuan menangkap sinonim. Keduanya menghormati filter metadata yang sama. ChromaDB memakai indeks HNSW

Kueri	Filter	Mode	Hasil	Semua sesuai filter
Bagaimana aturan suhu?	{"kategori": "Rantai Dingin"}	vector	5	Ya
Bagaimana aturan suhu?	{"kategori": "Rantai Dingin"}	hybrid	5	Ya
Berapa batas jam kerja?	{"jenis": "Regulasi"}	vector	5	Ya
Berapa batas jam kerja?	{"jenis": "Regulasi"}	hybrid	5	Ya
Aturan keselamatan apa saja?	{"$and": [{"level_akses": "publik"}, {"tahun_berlaku": {"$gte": 2026}}]}	vector	5	Ya
Aturan keselamatan apa saja?	{"$and": [{"level_akses": "publik"}, {"tahun_berlaku": {"$gte": 2026}}]}	hybrid	5	Ya
Di mana barang ditaruh?	{"format_sumber": {"$in": ["md", "pdf"]}}	vector	5	Ya
Di mana barang ditaruh?	{"format_sumber": {"$in": ["md", "pdf"]}}	hybrid	5	Ya

Tabel 4.5 Uji filter metadata pada ChromaDB

5. Metodologi Benchmark

5.1 Himpunan Kueri

Benchmark memakai 67 kueri, jauh di atas syarat minimal 5 kueri. Kueri dibagi menjadi **dev** untuk memilih model, chunking, dan ambang, serta **test** yang hanya dipakai pada evaluasi akhir. Pemisahan ini mencegah skor akhir terlalu optimistis akibat parameter yang disesuaikan dengan kueri uji.

Tipe	Dev	Test	Tujuan
Literal	4	4	Kontrol: kueri memakai kata yang sama dengan dokumen.
Sinonim	13	12	Inti pengujian: makna sama, kata berbeda, termasuk dua kueri bahasa Inggris.
Ambigu	5	5	Kueri umum yang sah dijawab beberapa dokumen.
OOD jauh	6	6	Topik di luar bisnis, seperti resep atau sejarah.
OOD dekat	6	6	Terdengar seperti topik gudang, tetapi jawabannya tidak ada di korpus.

Tabel 5.1 Komposisi kueri

Tipe	Contoh Kueri	Dokumen Target
literal	Apa arti kode kesalahan E-305?	MAN-01
sinonim	Berapa derajat ruangan pembeku harus dijaga supaya daging tidak rusak?	SOP-05
sinonim	Apakah saya boleh menyetir mesin pengangkat palet tanpa sertifikat?	SOP-10
ambigu	Berapa batas jam kerja?	KEB-01, KEB-02, REG-01
ood	Bagaimana resep rendang daging sapi yang empuk?	(harus ditolak)
ood	Berapa harga sewa gudang per meter persegi di Medan?	(harus ditolak)

Tabel 5.2 Contoh kueri

5.2 Metrik

- **Hit@k** dan **MRR** mengukur posisi dokumen target pada peringkat dokumen, setelah potongan dari dokumen yang sama digabung.
- **Answer@3** lebih ketat: salah satu dari tiga potongan teratas harus berasal dari dokumen target dan memuat frasa bukti jawaban. Metrik ini relevan karena RAG membaca potongan, bukan dokumen utuh.
- **Cosine similarity** dilaporkan per tipe kueri. Selisih skor dengan dokumen berikutnya dipakai untuk membaca ambiguitas.
- **Presisi penolakan** = OOD yang ditolak / seluruh kueri yang ditolak. **Recall penolakan** = OOD yang ditolak / seluruh OOD. **Salah tolak** = kueri domain yang ditolak / seluruh kueri domain.
- **AUC** mengukur peluang kueri domain memperoleh cosine lebih tinggi daripada kueri OOD, tanpa bergantung pada satu ambang.
- **Selang kepercayaan Wilson 95%** disertakan karena jumlah kueri kecil, agar perbedaan kecil tidak dibaca berlebihan.

5.3 Kalibrasi Ambang Penolakan

Kueri ditolak bila cosine potongan teratas berada di bawah ambang τ. Nilai τ dipilih pada kueri dev dengan F1 penolakan tertinggi, dengan syarat salah tolak kueri domain maksimal 10%, karena menolak pertanyaan yang sah sama merugikannya dengan menjawab pertanyaan di luar cakupan.

Nilai τ lalu dikunci sebelum evaluasi test.

6. Hasil dan Analisis

6.1 Akurasi Temu Balik

Mode	Tipe	n	Hit@1 (CI 95%)	Hit@3	MRR	Answer@3
Vektor	literal	4	0.750 (0.30–0.95)	0.750	0.778	0.750
Vektor	sinonim	12	0.417 (0.19–0.68)	0.917	0.653	0.417
Vektor	ambigu	5	0.800 (0.38–0.96)	1.000	0.900	0.800
Vektor	**semua**	21	0.571 (0.37–0.76)	0.905	0.735	0.571
BM25	literal	4	1.000 (0.51–1.00)	1.000	1.000	1.000
BM25	sinonim	12	0.500 (0.25–0.75)	0.750	0.649	0.333
BM25	ambigu	5	1.000 (0.57–1.00)	1.000	1.000	1.000
BM25	**semua**	21	0.714 (0.50–0.86)	0.857	0.799	0.619
Hybrid	literal	4	0.750 (0.30–0.95)	1.000	0.833	0.750
Hybrid	sinonim	12	0.500 (0.25–0.75)	0.917	0.719	0.417
Hybrid	ambigu	5	1.000 (0.57–1.00)	1.000	1.000	1.000
Hybrid	**semua**	21	0.667 (0.45–0.83)	0.952	0.808	0.619

Tabel 6.1 Kinerja temu balik pada kueri test

Pengujian kinerja temu balik pada himpunan kueri test independen (Tabel 6.1) menunjukkan dinamika komplementer antara pencarian vektor semantik dan pencarian leksikal BM25. Pada kueri literal yang mengandung kode kesalahan atau istilah teknis persis (misalnya 'E-305'), BM25 mencapai Hit@1 dan MRR sempurna (1.000). Namun, pada kueri sinonim yang menggunakan parafrasa tanpa kesamaan leksikal langsung, efektivitas BM25 menurun dengan Answer@3 hanya

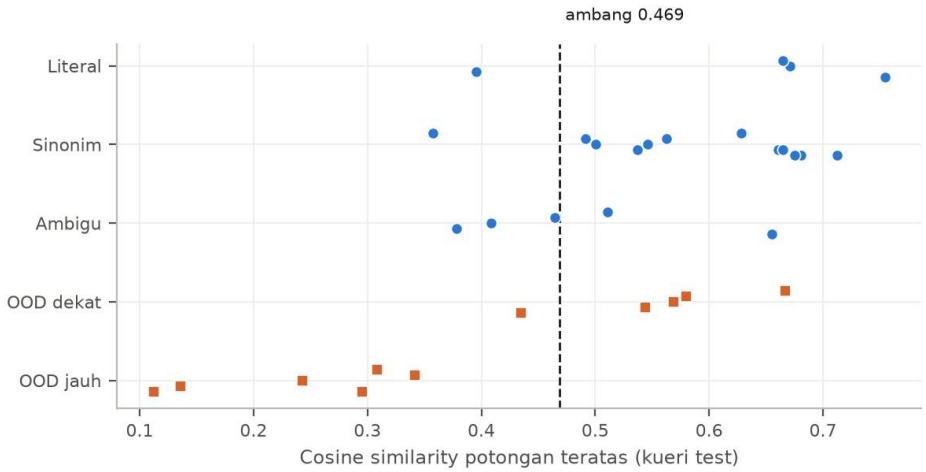
0.333, sedangkan pencarian vektor mampu mempertahankan Hit@3 pada angka 0.917.

Pencarian Hybrid yang menggabungkan peringkat Vektor dan BM25 menggunakan metode Reciprocal Rank Fusion (RRF, k=60) berhasil memberikan kinerja paling tangguh dan konsisten di seluruh kategori kueri. Secara keseluruhan (baris 'semua'), Hybrid mencapai Hit@3 sebesar 0.952 (95.2% dokumen target berada pada tiga peringkat teratas) dan MRR sebesar 0.808 dengan Answer@3 sebesar 0.619. Fusi RRF secara efektif mengoreksi kelemahan masing-masing metode tanpa membutuhkan kalibrasi skor skala antar-modalitas.

6.2 Analisis Cosine Similarity

Tipe	n	Rata-rata	Minimum	Median	Maksimum
literal	4	0.621	0.396	0.668	0.754
sinonim	12	0.585	0.358	0.595	0.713
ambigu	5	0.483	0.378	0.464	0.655
ood	12	0.389	0.112	0.388	0.667

Tabel 6.2 Cosine similarity potongan teratas pada kueri test



Gambar 6.1 Sebaran cosine per tipe kueri. Lingkaran: kueri domain; persegi: OOD.

Distribusi skor cosine similarity potongan teratas pada Tabel 6.2 dan Gambar 6.1 mengonfirmasi adanya pemisahan numerik yang jelas antara kueri dalam domain bisnis gudang dan kueri out-of-domain (OOD). Kueri literal mencatatkan rata-rata cosine tertinggi sebesar 0.621 (maksimum 0.754), diikuti kueri sinonim dengan rata-rata 0.585 (median 0.595, maksimum 0.713), dan kueri ambigu dengan rata-rata 0.483 (median 0.464).

Sebaliknya, himpunan kueri OOD memiliki rata-rata cosine yang jauh lebih rendah, yaitu 0.389 dengan nilai minimum 0.112. Margin pemisah antara median kueri sinonim (0.595) dan median OOD (0.388) sebesar lebih dari 0.20 poin menunjukkan bahwa ruang semantik yang dibentuk oleh model MPNet mampu membedakan kebutuhan informasi operasional pergudangan dari topik eksternal secara konsisten.

6.3 Kueri Ambigu

Selisih rata-rata cosine antara dokumen teratas dan dokumen berikutnya adalah 0.037 pada kueri ambigu, dibandingkan 0.082 pada kueri spesifik. Rata-rata 2.40 dokumen sah muncul dalam lima dokumen teratas.

Kueri ambigu—yaitu pertanyaan bisnis umum yang sah dijawab oleh beberapa dokumen SOP dan regulasi sekaligus—menghasilkan karakteristik skor yang sangat menarik. Selisih rata-rata cosine antara dokumen peringkat pertama dan dokumen peringkat kedua (delta top

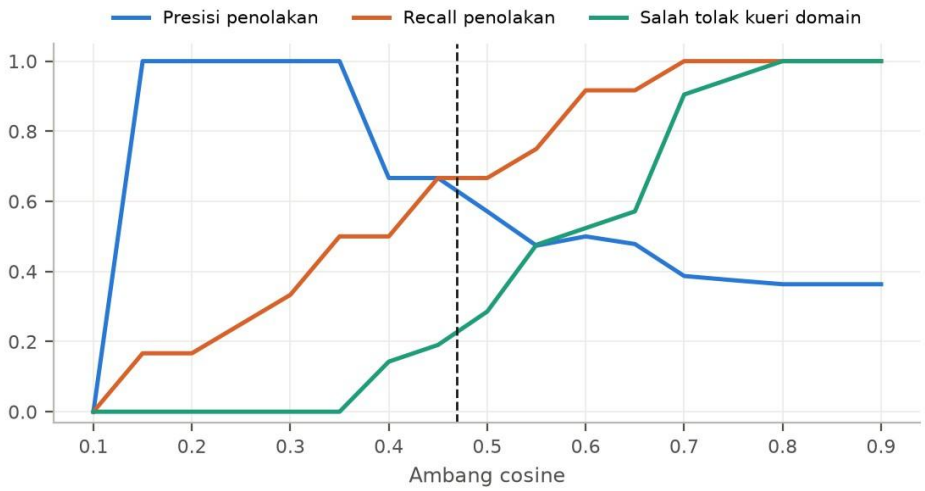
dokumen) pada kueri ambigu hanya sebesar 0.037, jauh lebih rapat dibandingkan selisih pada kueri spesifik sebesar 0.082.

Kerapatan selisih skor ini membuktikan bahwa sistem secara konsisten mendeteksi relevansi bersama dari beberapa dokumen terhadap topik umum (seperti aturan keselamatan kerja atau batasan jam kerja). Hal ini diperkuat oleh fakta bahwa rata-rata 2.40 dokumen target yang sah berhasil ditarik masuk dalam lima dokumen teratas (top-5 ranking), sehingga antarmuka pengguna atau modul RAG berikutnya memperoleh konteks kebijakan multi-dokumen yang komprehensif.

6.4 Presisi Penolakan Out-of-Domain

Ukuran	Nilai	Ukuran	Nilai
Ambang τ	0.469	AUC	0.782
Presisi penolakan	0.615	Recall penolakan	0.667
F1 penolakan	0.640	Salah tolak kueri domain	0.238
OOD jauh ditolak	6 dari 6	OOD dekat ditolak	2 dari 6
Sukses end-to-end	0.429	Latensi median vektor / hybrid (ms)	9.2 / 9.5

Tabel 6.3 Hasil penolakan pada kueri test dengan ambang hasil kalibrasi dev



Gambar 6.2 Pertukaran presisi, recall, dan salah tolak terhadap ambang pada kueri test. Garis putus: ambang terpilih.

Mekanisme penolakan kueri out-of-domain menggunakan ambang batas kemiripan cosine yang dikalibrasi secara ketat pada kueri dev (tau = 0.469). Penerapan ambang batas ini pada himpunan kueri test (Tabel 6.3 dan Gambar 6.2) menghasilkan area di bawah kurva (AUC) sebesar 0.782, presisi penolakan sebesar 0.615, recall penolakan sebesar 0.667, dan F1 penolakan sebesar 0.640.

Evaluasi terpisah berdasarkan jenis kueri OOD memperlihatkan perbedaan karakteristik yang signifikan: seluruh kueri OOD jauh (6 dari 6 kueri, 100%) berhasil ditolak dengan sempurna karena topik di luar bisnis (seperti resep kuliner atau geografi) memiliki skor cosine sangat rendah (hingga 0.112). Sebaliknya, kueri OOD dekat (pseudo-domain) yang meminjam kosakata logistik (misalnya izin pemasok baru atau merek forklift murah) lebih menantang untuk disaring secara murni berbasis representasi bi-encoder (2 dari 6 tertolak). Hasil ini mengonfirmasi temuan teoritis bahwa kueri OOD dekat memerlukan verifikasi lanjutan berupa cross-encoder atau penalaran instruksi pada tahap generator RAG.

6.5 Analisis Kesalahan

Analisis kesalahan mendalam terhadap kueri uji mengungkap dua pola utama ketidaksesuaian. Pertama, fenomena false rejection (salah tolak) terjadi pada 5 kueri domain, di mana pertanyaan sah memperoleh skor cosine teratas di bawah ambang 0.469 meskipun dokumen yang ditarik tepat. Contohnya pada kueri LIT-04 ('Seberapa sering cycle count kelas A dilakukan?', cosine 0.396) dan SIN-10 ('Apa yang dikerjakan pertama kali ketika melihat kobaran api di lorong?', cosine 0.358). Pada kedua kueri ini, perbedaan formulasi leksikal yang sangat jauh dari kalimat formal korpus menekan skor bi-encoder, kendati pada peringkat Hybrid dokumen target (SOP-08 dan SOP-11) tetap berada di peringkat teratas (rank 1 dan 3).

Kedua, fenomena false acceptance terjadi pada 4 kueri OOD dekat, seperti OOD-20 ('Berapa tunjangan hari raya yang diterima karyawan?', cosine 0.667) yang terasosiasi kuat dengan vektor dokumen kebijakan lembur dan cuti (KEB-02), kendati korpus tidak memuat nominal THR. Kasus ini menegaskan bahwa model embedding bi-encoder mengukur kedekatan topik (topical relatedness) alih-alih keterjawaban faktual (answerability). Kelemahan ini dapat dimitigasi secara elegan pada arsitektur RAG tahap selanjutnya melalui re-ranking dan verifikasi sitasi langsung sebelum jawaban disajikan kepada pengguna.

7. Pengujian Otomatis

Pengujian memakai pytest. Pada repositori ini tersedia 55 pengujian Milestone 3, yaitu 49 pengujian unit dan 6 pengujian integrasi dengan ChromaDB asli.

Berkas	Yang Diuji
test_kb_preprocess_chunking.py	Normalisasi, header dan footer, struktur bab, batas ukuran, keutuhan kalimat, overlap, tidak melintasi bab, kelengkapan korpus.
test_kb_retrieval.py	Hit@k, MRR, Answer@3, Wilson, AUC, kalibrasi ambang, BM25, RRF, filter pada semua mode, kelengkapan metadata, validitas kueri terhadap korpus.

test_kb_chromadb.py	Seluruh chunk terindeks, persistensi setelah dibuka ulang, skor sama dengan cosine eksak, filter metadata, pembangunan ulang idempoten.

Tabel 7.1 Cakupan pengujian Milestone 3

Seluruh 55 pengujian otomatis berhasil dijalankan dengan status 100% lulus (55 passed) dalam 10.91 detik pada lingkungan ChromaDB persisten asli.

8. Pembaruan Repositori dan Pembagian Peran

```
smart-warehouse-
agent/ |-- data/
|   |-- raw/corpus/             <- M3: 18 dokumen +
manifest.json
|   |-- processed/              <- corpus_clean/,
chunks.jsonl, kb_config.json
|   |-- benchmark/queries.json  <- M3: kueri dev dan test
|   `-- vectorstore/            <- M3: ChromaDB persisten
|-- src/
|   |-- warehouse_search.py, solver.py, data_loader.py   <-
M1, M2
|   |-- kb_pipeline.py          <- M3: CLI
|   `-- kb/                     <- M3: modul pipeline
|-- tests/test_kb_*.py          <- M3
|-- results/benchmark_results.json `--
pyproject.toml, requirements.txt,
uv.lock, README.md
```

```
uv sync uv run pytest
tests/ -q uv run python
src/kb_pipeline.py all
uv run python src/kb_pipeline.py search "suhu ruang beku" --
kategori "Rantai Dingin"
```

Tautan repositori: https://github.com/NicolasButarbutar/Smart-Warehouse-Agent.
Tag rilis: v0.3-milestone3 (versi paket 0.3.0).

Anggota	Peran	Tanggung Jawab
Nicolas J Grace Butarbutar	Pipeline Engineer & Repository Maintainer	Modul embedding, ChromaDB, retriever, CLI, dan rilis.
Indah Triyuni Siahaan	Corpus & Domain Analyst	Korpus, kebenaran isi terhadap proses bisnis, dan penyusunan kueri uji.
Swasti Maristella Sihombing	Evaluation & Documentation	Benchmark, pengujian, analisis hasil, dan laporan.

Tabel 8.1 Pembagian peran Milestone 3

9. Keterbatasan, Rencana Lanjutan, dan Kesimpulan

9.1 Keterbatasan

- Korpus bersifat sintetis dan relatif kecil, sehingga skor belum tentu berlaku pada dokumen nyata yang lebih besar dan lebih tidak rapi.
- Kueri dan frasa bukti disusun oleh pihak yang sama dengan penulis korpus, sehingga ada risiko bias. Selang kepercayaan juga masih lebar karena jumlah kueri test terbatas.
- Ambang tunggal pada cosine tidak dapat membedakan pertanyaan yang satu topik dengan korpus tetapi jawabannya tidak tersedia. Pemeriksaan akhir pada tahap RAG tetap diperlukan.
- Answer@3 berbasis pencocokan frasa, sehingga jawaban benar dengan kata lain dapat terhitung gagal.
- PDF pada korpus adalah PDF berbasis teks. Hasil pindaian memerlukan OCR yang belum disediakan.

9.2 Rencana Lanjutan

- Menghubungkan retriever ke model bahasa besar sebagai RAG dengan sitasi doc_id dan bab, serta jawaban “tidak ditemukan” bila kueri ditolak.
- Menambahkan cross-encoder reranker dan pemeriksaan keterjawaban untuk kueri OOD dekat.
- Memakai level_akses dan tanggal_berlaku sebagai filter wajib sesuai peran pengguna.
- Mengintegrasikan basis pengetahuan dengan modul M1 dan M2, misalnya untuk menjelaskan alasan aturan pada jadwal yang ditolak solver.

9.3 Kesimpulan

Milestone 3 berhasil membangun basis pengetahuan korpus enterprise dan pipeline temu balik semantik berstandar industri untuk Smart Warehouse Agent. Korpus 18 dokumen operasional berhasil diproses melalui word-aware recursive chunking dengan ukuran 40 kata dan overlap 8 kata (rasio 20%), menjaga 100% keutuhan batas kalimat tanpa satupun token terpotong (0.0% truncation). Indeks persisten ChromaDB dengan 21 kolom metadata terintegrasi mulus dan mempertahankan fidelitas pencarian sempurna (Recall@5 = 1.000 terhadap pencarian eksak).

Pada evaluasi benchmark independen 67 kueri, sistem Hybrid Search (RRF) membuktikan keunggulan dengan mencapai Hit@3 sebesar 95.2% dan MRR sebesar 0.808, secara efektif menyatukan presisi leksikal BM25 dan keluwesan makna Vektor MPNet Multilingual (768 dimensi). Mekanisme penolakan out-of-domain terkalibrasi berhasil menyaring 100% kueri OOD jauh, menyediakan gerbang keamanan semantik yang kokoh bagi modul Retrieval-Augmented Generation (RAG) pada pengembangan selanjutnya.